

O que é LLM?

LLM é um modelo de linguagem formado por uma rede neural artificial com muitos parâmetros para gerar tarefas de Processamento de Linguagem Natural (NLP), um subcampo da inteligência artificial que se preocupa em fornecer ao computador a capacidade de processar dados codificados em "Linguagem Natural".

Nesse contexto, quando se fala em "Linguagem Natural", refere-se à linguagem humana. A sigla LLM significa "Large Language Model", que ao traduzir do inglês, adaptando ao português, fica "Modelo de Linguagem em Grande Escala".

Atualmente, os modelos mais conhecidos são os desenvolvidos pela OpenAI, Google e Meta.

Geralmente, a análise de dados é feita através de uma grande quantidade de textos utilizando-se de trilhões de parâmetros.

O que são parâmetros de um LLM?

Parâmetros são instruções criadas para que a inteligência artificial possa reconhecer padrões ao analisar as informações. Quanto maior o número de parâmetros, maior a capacidade de um modelo de linguagem reconhecer interações complexas entre os dados obtidos.

Quais são as aplicações de um LLM?



Inteligência artificial (Imagem: Pixabay/Geralt)

As LLMs podem ser utilizados para diversas aplicações que envolvem a análise e geração dados no formato de textos, imagens e vídeos. Os modelos de linguagem em grande escala mais populares são o ChatGPT e o Gemini, mas há outros além destes.

Os chatbos da OpenAI e do Google, através da utilização de inteligência artificial, são capazes de realizar tarefas como, por exemplo:

- Resumir textos longos;

- Corrigir erros gramaticais de textos;
- Traduzir redações;
- Conversar com humanos;
- Responder às perguntas de uma pessoa;
- Gerar texto após a análise de uma imagem;
- Criar um modelo 3D de uma cena descrita em texto;
- Gerar uma descrição para o que foi exibido em um vídeo;
- Converter trechos de textos para mudar o tipo de abordagem como, por exemplo, para uma que seja mais formal.

Como funciona um LLM?

Um LLM funciona através da análise da linguagem humana ao processar grandes quantidades de textos por meio de trilhões de parâmetros, que são regras criadas para o reconhecimento de padrões. Desta forma, o modelo de linguagem interpreta informações apresentadas para produzir uma resposta.

Os parâmetros do LLM utilizam “pesos” para determinar o relacionamento entre a entrada (prompt, comando) e a saída (resposta). Estes pesos são “aprendidos” através do treinamento do sistema de inteligência artificial, que é realizado através de Redes Neurais Artificiais (RNAs).

As Redes Neurais Artificiais são modelos computacionais inspirados pelo sistema nervoso central do nosso cérebro. Estes modelos utilizam técnicas de machine

learning, a base do deep learning (aprendizado profundo), subcampo do aprendizado de máquina, que traz múltiplas camadas dentro de uma RNA.

A ideia de múltiplas camadas é tentar imitar a forma com que o cérebro humano processa, por exemplo, a luz e a audição. Há camadas com estruturas diferentes, que variam de acordo com o problema. Para que o funcione, há um sistema de hierarquias de características, indo de um nível baixo para um nível alto.



Inteligência artificial (Imagem: Max Pixel)

Desde o boom de sistemas de IA Generativos em 2020, uma arquitetura de deep learning chamada "transformer" tem sido aplicada LLMs como ChatGPT, Gemini, LLaMA, Copilot, entre outros.

Como os Large Language Models são treinados?

Os principais LLMs existentes utilizam redes neurais artificiais treinadas através de uma arquitetura baseada em "transformer", que é um tipo de arquitetura de aprendizado profundo.

A "transformer" foi desenvolvida por pesquisadores do Google e funciona através do mecanismo "multi-head attention", proposto em 2017. O mecanismo "multi-head attention" funciona convertendo um texto em representações numéricas chamadas tokens.

A "transformer" é útil para os LLMs, pois requer menos tempo de treinamento que outros tipos de arquiteturas de deep learning. Hoje há variações da "transformer" que são utilizadas para treinar grandes LLMs, como a corpus da Wikipedia e a Common Crawl.

Quais são as vantagens de um LLM?

A maior vantagem de um LLM está na capacidade de utilizar múltiplos tipos de dados (texto, áudio e imagem). Com o multimodal learning, um tipo de deep learning, combina-se diferentes modelos unimodais, gerando respostas com informações mais precisas. Além disso, o LLM apresenta outras vantagens como:

- **Compreensão da linguagem natural**, humana, facilitando a interação com o usuário.
- **Geração de conteúdo a partir da inteligência artificial**, podendo ser no formato de texto, áudio, imagem ou vídeo.

- Adaptação a contextos**, analisando a interação do conteúdo dos prompts que o usuário criou com as respostas.

- Treinamento contínuo** por meio de atualizações dos parâmetros e adição de mais informações para a base de dados.

- Utilização de aprendizado multimodal (multimodal learning)**, que é a capacidade de analisar e responder de forma combinada utilizando diversos tipos de conteúdo (texto, áudio, vídeo, imagem).

Os LLMs possuem um grande potencial para diversas áreas da tecnologia, trazendo uma revolução para vários processos.

Quais são as limitações de um LLM?

O principal limitador de um LLM é o número de parâmetros que o modelo possui. Embora seja possível ajustar um parâmetro através de treinamentos, como as informações advêm de interações entre pessoas e produção de conteúdo na internet, existem barreiras que ainda são difíceis de transpassar. Entre as limitações, estão:

- Viés na apresentação de informações subjetivas ou que dependem de uma complexa interação de diferentes campos do conhecimento.

- Dependência de atualizações para alimentar o LLM com novos dados de informações e parâmetros.

- Número de padrões insuficiente para a interpretação das informações apresentadas e geração de respostas mais precisas.

- Tempo necessário para o LLM o treinamento de análise de informações.

- Alto custo para o processamento de dados do LLM.

Devido às limitações atuais da tecnologia de IA Generativa dos LLMs, está claro que embora haja um grande potencial, é necessário ter cautela com seu uso
